Análisis de Potencial Solar en Territorios PDET de Colombia

Informe Técnico Final

Administración de Bases de Datos

Curso: Administración de Bases de Datos

Profesor: Andrés Oswaldo Calderón Romero, Ph.D.

Grupo: *[Nombre del grupo]*

Integrantes: *Sara Albarracin Niño*
Juan Pablo Casas
Jineth Tatiana Vivas Barón
Andrés Felipe Galan Cardenas

Fecha: 11 de mayo de 2026

Proyecto desarrollado en el marco de la iniciativa de la Unidad de Planeación Minero Energética (UPME) para la identificación de zonas aptas para energía solar fotovoltaica.

Resumen Ejecutivo

[Completar al finalizar el proyecto. Incluir: objetivo principal, metodología empleada, principales hallazgos numéricos (número de municipios PDET analizados, cantidad de edificaciones, área total de techos) y recomendaciones clave.]

Palabras clave: energía solar, territorios PDET, análisis geoespacial, NoSQL, Microsoft Building Footprints, Google Open Buildings, Colombia.

Índice general

Resumen Ejecutivo **1**

1. Introducción **7**
1.1. Contexto general 7
1.2. Motivación 7
1.3. Objetivo general 7
1.4. Objetivos específicos 8
1.5. Alcance y limitaciones 8
1.6. Estructura del informe 8

2. Marco Teórico **9**
2.1. Energía solar fotovoltaica: fundamentos 9
2.2. Territorios PDET y equidad energética 9
2.3. Detección de edificaciones mediante imágenes satelitales 9
2.3.1. Microsoft Building Footprints 10
2.3.2. Google Open Buildings 10
2.3.3. GlobalBuildingAtlas (TUM) 10
2.4. Sistemas de gestión de bases de datos NoSQL 10
2.4.1. Motivación para NoSQL en datos geoespaciales 10
2.4.2. MongoDB y operaciones geoespaciales 10
2.4.3. Alternativas consideradas 11
2.5. Marco Geoestadístico Nacional (MGN) 11
2.6. Índices espaciales y eficiencia de consultas 11

3. Diseño del Esquema NoSQL e Plan de Implementación **12**
3.1. Plan de implementación 12
3.1.1. Pila tecnológica 13
3.2. Modelado de datos 13
3.3. Diseño del esquema 13
3.4. Justificación de la solución NoSQL 15
3.5. Avance y resultados de la Semana 1 16

4. Integración del Dataset de Municipios PDET **18**
4.1. Adquisición de datos — MGN DANE . . . 18
4.1.1. Verificación de integridad . . . 18
4.2. Identificación y filtrado de municipios PDET . . . 19
4.3. Integración espacial en NoSQL . . . 19
4.3.1. Preprocesamiento y exportación a GeoJSON . . . 20
4.3.2. Carga en MongoDB Atlas . . . 21
4.4. Validación de la carga . . . 22
4.5. Avance y resultados de la Semana 2 . . . 23

5. Carga e Integración de Datos de Edificaciones **25**
5.1. Datasets seleccionados . . . 25
5.2. Dataset 1: Microsoft Building Footprints . . . 25
5.2.1. Adquisición . . . 25
5.2.2. Formato y estructura . . . 25
5.2.3. Carga en NoSQL . . . 26
5.2.4. Análisis exploratorio (EDA) . . . 26
5.3. Dataset 2: Google Open Buildings . . . 26
5.3.1. Adquisición . . . 26
5.3.2. Carga en NoSQL e índices espaciales . . . 26
5.3.3. Análisis exploratorio (EDA) . . . 26
5.4. Comparación preliminar de datasets . . . 26
5.5. Avance y resultados de la Semana 3 . . . 26

6. Flujo de Trabajo Geoespacial Reproducible **27**
6.1. Metodología de análisis espacial . . . 27
6.1.1. Intersección espacial en NoSQL . . . 27
6.1.2. Reproducibilidad . . . 28
6.2. Resultados por municipio PDET . . . 28
6.2.1. Dataset Microsoft . . . 28
6.2.2. Dataset Google . . . 28
6.3. Visualizaciones . . . 29
6.4. Comparación entre datasets . . . 29
6.5. Avance y resultados de la Semana 4 . . . 29

7. Resultados Finales y Recomendaciones para UPME **30**
7.1. Síntesis de resultados . . . 30
7.2. Análisis de potencial solar . . . 30
7.3. Municipios prioritarios para proyectos piloto . . . 31
7.4. Recomendaciones para UPME . . . 31

7.5. Limitaciones y trabajo futuro 31

8. Conclusiones **32**

A. Repositorio y Estructura de Archivos **33**

B. Diccionario de Datos **34**

C. Instrucciones de Reproducción **35**

Índice de figuras

4.1. Municipios PDET en Colombia — Fuente: DANE MGN2025, elaboración propia. 23

6.1. Área total de techumbres por municipio PDET según cada dataset. . . 29

7.1. Municipios PDET priorizados para proyectos piloto de energía solar. . . 31

Índice de cuadros

3.1. Pila tecnológica del proyecto 13
3.2. Colecciones de la base de datos `upme_solar_db` 13
3.3. Comparación de motores NoSQL evaluados 16

4.1. Municipios PDET por subregión — Fuente: ART / Decreto 893 de 2017 19
4.2. Esquema de documento — Colección `municipios_pdet` 21
4.3. Resultados de la verificación de integridad del dataset PDET 22

5.1. Comparación de datasets de edificaciones para Colombia 26

6.1. Top 10 municipios PDET por área total de techumbres — Microsoft . . 28

Capítulo 1

Introducción

1.1. Contexto general

Colombia atraviesa una transformación acelerada de su matriz energética orientada hacia fuentes renovables (**iea2023colombia**). En este marco, la Unidad de Planeación Minero Energética (UPME) lidera iniciativas para identificar territorios con potencial para la instalación de soluciones de energía solar, con énfasis en los Programas de Desarrollo con Enfoque Territorial (PDET) (**upme2022plan**).

Los territorios PDET, establecidos por el Decreto 893 de 2017 como parte de la implementación del Acuerdo de Paz, comprenden 170 municipios en 16 subregiones prioritarias del país. Estas zonas combinan rezago histórico en infraestructura con condiciones geográficas favorables para la captación de energía solar (**arteaga2021pdet**).

1.2. Motivación

La estimación del área de techumbres disponible para paneles solares a escala municipal es una tarea que requiere el procesamiento eficiente de grandes volúmenes de datos geoespaciales. Los conjuntos de datos de edificaciones derivados de imágenes satelitales —como Microsoft Building Footprints y Google Open Buildings— representan recursos valiosos para este fin, pero su magnitud (más de mil millones de registros) impone el uso de tecnologías de almacenamiento y consulta escalables (**microsoft2023buildings**; **sirko2021continental**).

1.3. Objetivo general

Diseñar e implementar un flujo de trabajo geoespacial reproducible, basado en soluciones NoSQL, para estimar el número de edificaciones y el área total de techumbres aptas para instalación de paneles solares en los municipios PDET de Colombia.

1.4. Objetivos específicos

1. Diseñar un esquema NoSQL adecuado para el almacenamiento y consulta eficiente de datos geoespaciales a escala nacional.
2. Integrar las capas de límites administrativos PDET provenientes del Marco Geoestadístico Nacional (MGN) del DANE.
3. Cargar y validar al menos dos conjuntos de datos de edificaciones (Microsoft y/o Google y/o GlobalBuildingAtlas).
4. Ejecutar operaciones de intersección espacial para estimar el conteo y área de techumbres por municipio PDET.
5. Elaborar visualizaciones y recomendaciones para UPME.

1.5. Alcance y limitaciones

[Describir qué queda dentro y fuera del alcance: municipios analizados, versiones de datasets utilizados, supuestos sobre inclinación de techos, etc.]

1.6. Estructura del informe

El presente informe se organiza en cinco capítulos que corresponden a las cinco entregas semanales del proyecto, seguidos de conclusiones y referencias.

Capítulo 2

Marco Teórico

2.1. Energía solar fotovoltaica: fundamentos

La energía solar fotovoltaica convierte la radiación solar directamente en electricidad mediante el efecto fotoeléctrico (**luque2011handbook**). El potencial de generación depende fundamentalmente de la irradiancia global horizontal (GHI) y del área efectiva de captación disponible. Colombia, al encontrarse entre los 4,0° N y 12,0° N de latitud, presenta valores de GHI superiores a 4,5 kWh/m^2/día en gran parte de su territorio (**atlas2020solar**).

2.2. Territorios PDET y equidad energética

Los territorios PDET fueron definidos por el Decreto 893 de 2017 como áreas prioritarias para la implementación del punto uno del Acuerdo Final de Paz, relacionado con la Reforma Rural Integral (**decreto893_2017**). La literatura evidencia que estas regiones exhiben déficits persistentes en cobertura eléctrica, lo cual refuerza la pertinencia de explorar soluciones descentralizadas como la generación solar distribuida (**rodriguez2020energia**).

2.3. Detección de edificaciones mediante imágenes satelitales

La extracción automática de huellas de edificaciones a partir de imágenes satelitales de alta resolución se apoya en arquitecturas de aprendizaje profundo, especialmente redes neuronales convolucionales (CNN) y modelos de segmentación semántica como U-Net (**ronneberger2015unet**).

2.3.1. Microsoft Building Footprints

El conjunto de datos de Bing Maps comprende más de 999 millones de detecciones de edificios derivadas de imágenes Maxar y Airbus recopiladas entre 2014 y 2021. El modelo de detección utiliza una arquitectura ResNet entrenada con datos etiquetados manualmente, alcanzando una precisión superior al 90 % en zonas urbanas (**microsoft2023buildings**). Los datos se distribuyen bajo la licencia ODbL.

2.3.2. Google Open Buildings

Sirko et al. (**sirko2021continental**) presentan un conjunto de datos con 1 800 millones de detecciones que cubre África, Asia meridional, América Latina y el Caribe. La tercera versión del dataset incorpora mejoras en regiones de vegetación densa y zonas rurales. Se distribuye bajo licencias CC BY-4.0 y ODbL.

2.3.3. GlobalBuildingAtlas (TUM)

Desarrollado por la Universidad Técnica de Múnich, este atlas contiene 2 750 millones de modelos tridimensionales de edificios con resolución espacial de 3×3 m, derivados de imágenes satelitales de 2019 (**geiÃ§2022global**). La disponibilidad de atributos de altura permite estimar volumen y pendiente del techo.

2.4. Sistemas de gestión de bases de datos NoSQL

2.4.1. Motivación para NoSQL en datos geoespaciales

El paradigma NoSQL surge como respuesta a las limitaciones de los sistemas relacionales para manejar datos no estructurados, distribuidos y de gran volumen (**han2011survey**). En el contexto geoespacial, las bases de datos de documentos y los sistemas orientados a columnas ofrecen ventajas significativas en términos de escalabilidad horizontal y flexibilidad de esquema.

2.4.2. MongoDB y operaciones geoespaciales

MongoDB implementa índices geoespaciales de tipo `2dsphere` compatibles con el estándar GeoJSON (**mongodb2023geo**). Sus operadores `$geoIntersects` y `$geoWithin` permiten consultas de intersección y contención poligonal directamente sobre los documentos almacenados.

2.4.3. Alternativas consideradas

[Completar con otras opciones evaluadas: PostgreSQL/PostGIS como referencia relacional, Apache Cassandra, Amazon DynamoDB, etc., y justificar la elección final.]

2.5. Marco Geoestadístico Nacional (MGN)

El MGN, publicado por el DANE, constituye el sistema de referencia cartográfica oficial de Colombia. Su capa municipal incluye los polígonos de los 1 122 municipios del país con sus respectivos códigos DIVIPOLA (**dane2025mgn**). Para este proyecto se utiliza la versión MGN2025.

2.6. Índices espaciales y eficiencia de consultas

Los índices espaciales de tipo R-tree permiten realizar búsquedas de proximidad e intersección en tiempo $O(\log n)$ en lugar de $O(n)$ (**guttman1984rtree**). Su implementación en bases de datos NoSQL es fundamental para procesar consultas sobre millones de polígonos de edificaciones en tiempos razonables.

Capítulo 3

Diseño del Esquema NoSQL e Plan de Implementación

Semana 1 — Entrega 1

Objetivo: Diseñar el esquema NoSQL y elaborar el plan de implementación tecnológica del proyecto.
Fecha de entrega: Semana 1, antes de las 14:00 h.

3.1. Plan de implementación

El proyecto se ejecuta sobre una arquitectura de base de datos documental alojada en **MongoDB Atlas** (capa gratuita, clúster `Cluster0`, región US-East), accedida desde un entorno local de Python 3.13. El procesamiento geoespacial se realiza con GeoPandas y Shapely; la conexión a MongoDB, con PyMongo 4.x. Los notebooks de Jupyter Lab documentan cada etapa del flujo de manera reproducible y permiten la regeneración de todos los resultados a partir de los datos crudos. El control de versiones y la entrega de todos los artefactos del proyecto se gestionan con Git y GitHub.

3.1.1. Pila tecnológica

Cuadro 3.1: Pila tecnológica del proyecto

Componente	Descripción	Versión
Base de datos	MongoDB Atlas (nube, clúster M0 compartido)	7.x
Lenguaje principal	Python	3.13
Procesamiento geo	GeoPandas / Shapely	latest
Driver NoSQL	PyMongo	4.x
Notebooks	Jupyter Lab	latest
Visualización	Folium / Matplotlib	latest
Control de versiones	Git / GitHub	—

3.2. Modelado de datos

La base de datos `upme_solar_db` contiene tres colecciones cuyo diseño parte del principio de separación de roles: una colección territorial de referencia y dos colecciones de footprints, una por cada fuente de datos.

Cuadro 3.2: Colecciones de la base de datos `upme_solar_db`

Colección	Fuente	Rol en el proyecto	Docs aprox.
`municipios_pdet`	DANE / MGN 2025	Polígonos de referencia territorial	≈170
`ms_buildings`	Microsoft Bing Maps	Footprints de edificios — Dataset 1	Millones
`goo_buildings`	Google Open Bldgs V3	Footprints de edificios — Dataset 2	Millones

Las colecciones de edificaciones no referencian directamente a `municipios_pdet` mediante claves foráneas; la relación se establece en tiempo de consulta mediante operaciones `$geoIntersects` sobre los índices espaciales `2dsphere`. El campo `cod_dane_municipio` se inicializa en `null` y se asigna durante el análisis espacial de la Semana 4.

3.3. Diseño del esquema

El modelo adopta un diseño minimalista orientado a las consultas espaciales. Las decisiones de diseño más importantes son:

- **Sin embedding de estadísticas:** los conteos y áreas de techumbres no se embeben en `municipios_pdet`; se calculan en tiempo de consulta con el aggregation pipeline, evitando actualizaciones costosas al cargar nuevos footprints.

- **Sin referencia cruzada rígida:** `cod_dane_municipio` en las colecciones de edificaciones inicia en `null` y se asigna en el análisis de la Semana 4, lo que permite cargar los datasets independientemente del orden.

```
{
  "_id":            ObjectId,
  "cod_dane":       "05001",      // Codigo DANE - 5 digitos, indice unico
  "nombre":         "Medellin",
  "departamento":   "Antioquia",
  "pdet":           true,         // Siempre true en esta coleccion
  "subregion_pdet": "Bajo Cauca y Nordeste Antioqueno",
  "area_km2":       380.64,       // Calculada con GeoPandas (EPSG:9377)
  "geometry": {                   // Campo indexado 2dsphere
    "type": "MultiPolygon",
    "coordinates": [ [ [ [lng, lat], ... ] ] ]
  },
  "bbox": {                       // Bounding box precalculado
    "min_lng": -75.62, "max_lng": -75.51,
    "min_lat":   6.18, "max_lat":   6.34
  },
  "fuente":     "MGN2025",
  "cargado_en": ISODate("2025-XX-XX")
}
```

Listing 3.1: Esquema — Coleccion municipios_pdet

```
{
  "_id": ObjectId,
  "geometry": {                   // Campo indexado 2dsphere
    "type": "Polygon",
    "coordinates": [ [ [lng, lat], ... ] ]
  },
  "area_m2":            142.87,   // Calculada con GeoPandas (EPSG:9377)
  "cod_dane_municipio": null,     // Asignado en analisis Semana 4
  "fuente":             "microsoft",
  "cargado_en":         ISODate("2025-XX-XX")
}
```

Listing 3.2: Esquema — Coleccion ms_buildings

```
{
  "_id": ObjectId,
  "geometry": {                    // Campo indexado 2dsphere
    "type": "Polygon",
    "coordinates": [ [ [lng, lat], ... ] ]
  },
  "area_m2":            98.34,    // Tomado del campo
     area_in_meters del CSV
  "confidence":          0.872,   // Score de confianza [0.0 -
     1.0]
  "cod_dane_municipio":  null,    // Asignado en analisis
     Semana 4
  "fuente":             "google",
  "cargado_en":         ISODate("2025-XX-XX")
}
```

Listing 3.3: Esquema — Coleccion goo_buildings

Los índices definidos para las tres colecciones son:

```
// municipios_pdet
db.municipios_pdet.createIndex({ geometry: "2dsphere" })
db.municipios_pdet.createIndex({ cod_dane: 1 }, { unique: true
   })

// ms_buildings
db.ms_buildings.createIndex({ geometry: "2dsphere" })
db.ms_buildings.createIndex({ cod_dane_municipio: 1 })

// goo_buildings
db.goo_buildings.createIndex({ geometry: "2dsphere" })
db.goo_buildings.createIndex({ cod_dane_municipio: 1 })
db.goo_buildings.createIndex({ confidence: -1 })
```

Listing 3.4: Indices definidos en upme_solar_db

3.4. Justificación de la solución NoSQL

Se seleccionó MongoDB como motor NoSQL frente a las alternativas evaluadas (Couchbase, Cassandra y Elasticsearch) por cinco razones técnicas:

1. **Compatibilidad nativa con GeoJSON:** los tres datasets candidatos distribuyen sus datos en formato GeoJSON, que MongoDB almacena y consulta de forma nativa sin transformaciones intermedias.

2. **Índice `2dsphere`:** diseñado específicamente para geometrías sobre la superficie terrestre, habilita `$geoIntersects` y `$geoWithin` directamente en el motor.

3. **Ecosistema Python:** PyMongo integra MongoDB con GeoPandas, Shapely y Jupyter Lab, las herramientas centrales del flujo de trabajo.

4. **Esquema flexible:** los footprints de edificios tienen atributos variables según la fuente (Microsoft no incluye `confidence`; Google sí). Un esquema documental evita migraciones rígidas al comparar fuentes heterogéneas.

5. **Escalabilidad:** MongoDB puede distribuirse en clúster para manejar cientos de millones de registros sin cambiar la API de consulta.

Cuadro 3.3: Comparación de motores NoSQL evaluados

Motor NoSQL	Soporte geo	Curva aprend.	Veredicto
MongoDB	Nativo (`2dsphere`)	Baja	**Seleccionado**
Couchbase	Parcial (N1QL)	Media	Descartado
Cassandra	No nativo	Alta	Descartado
Elasticsearch	`geo_shape`	Media-alta	Descartado

3.5. Avance y resultados de la Semana 1

Durante esta primera entrega se completaron las siguientes tareas:

1. **Selección del motor NoSQL:** MongoDB 7.x en Atlas, justificado por su soporte nativo de índices `2dsphere` y compatibilidad directa con GeoJSON.

2. **Selección de datasets:** Microsoft Building Footprints y Google Open Buildings V3. El dataset GlobalBuildingAtlas (TUM) fue descartado por su licencia restrictiva (Commons Clause) y la complejidad de sus modelos 3D.

3. **Diseño del modelo de datos:** tres colecciones definidas (`municipios_pdet`, `ms_buildings`, `goo_buildings`) con sus esquemas de documento, campos obligatorios e índices espaciales.

4. **Plan de implementación:** flujo de trabajo de cuatro etapas documentado — adquisición, carga, análisis y reporte— con cronograma semanal alineado a las fechas de entrega del curso.

5. **Repositorio Git:** inicializado con la estructura de carpetas del proyecto y los dos documentos entregables de la semana 1 (*Modelado de Datos NoSQL* y *Plan de Implementación NoSQL*).

Capítulo 4

Integración del Dataset de Municipios PDET

Semana 2 — Entrega 2

Objetivo: Adquirir, limpiar e integrar los límites administrativos de los municipios PDET en la base de datos NoSQL.
Fecha de entrega: Semana 2, antes de las 14:00 h (defensa en clase).

4.1. Adquisición de datos — MGN DANE

Los límites administrativos municipales se obtuvieron a partir del **Marco Geoestadístico Nacional (MGN), versión 2025**, publicado por el DANE (**dane2025mgn**). El dataset se descargó en formato Shapefile y está compuesto por cuatro archivos: `MGN_ADM_MPIO_GRAFICO.shp` (95 MB), `.shx`, `.dbf` y `.prj`. La capa contiene los polígonos de los **1 122 municipios** de Colombia junto con sus atributos administrativos (códigos DIVIPOLA, nombres oficiales, tipo de municipio y año de actualización cartográfica).

4.1.1. Verificación de integridad

El Shapefile fue cargado en Python con la biblioteca GeoPandas (motor `pyogrio`) y se verificaron las siguientes propiedades:

- **Sistema de referencia:** EPSG:4686 (MAGNA-SIRGAS), sistema oficial de Colombia, confirmado mediante el archivo `.prj`.
- **Conteo de registros:** 1 122 municipios, coincidente con el total oficial de divisiones político-administrativas del país.

- **Atributos principales:** `mpio_cdpmp` (código DIVIPOLA de 5 dígitos), `mpio_cnmbr` (nombre oficial), `dpto_cnmbr` (nombre del departamento), `mpio_nano` (año de actualización cartográfica).

4.2. Identificación y filtrado de municipios PDET

La lista oficial de municipios PDET se obtuvo del archivo **MunicipiosPDET.xlsx**, derivado de los listados publicados por la Agencia de Renovación del Territorio (ART) en cumplimiento del Decreto 893 de 2017 (**decreto893_2017**). Este archivo contiene 170 registros con los campos: código de departamento, código de municipio (DANE), nombre del municipio, departamento y subregión PDET.

El cruce con la capa del MGN se realizó mediante un *inner join* sobre el campo **`cod_dane`** (código DIVIPOLA de 5 dígitos, con relleno de ceros a la izquierda), lo que produjo exactamente **170 municipios** coincidentes, cubriendo las **16 subregiones PDET** definidas por el Acuerdo de Paz.

Cuadro 4.1: Municipios PDET por subregión — Fuente: ART / Decreto 893 de 2017

Subregión PDET	**Departamentos principales**	**Municipios**
Bajo Cauca y Nordeste Antioqueño	Antioquia	11
Urabá Antioqueño	Antioquia, Chocó	11
Chocó	Chocó	27
Pacífico Medio	Chocó, Valle del Cauca	10
Pacífico y Frontera Nariñense	Nariño	22
Alto Patía y Norte del Cauca	Cauca, Nariño	24
Cuenca del Caguán y Pied. Caqueteño	Caquetá, Huila	8
Macarena – Guaviare	Meta, Guaviare	11
Putumayo	Putumayo	11
Sur de Bolívar	Bolívar, Antioquia	11
Sierra Nevada – Perijá	Magdalena, Cesar, La Guajira	17
Montes de María	Bolívar, Sucre	15
Sur de Córdoba	Córdoba	6
Catatumbo	Norte de Santander	9
Arauca	Arauca	7
Bajo Nordeste y Magdalena Medio	Bolívar, Santander, Antioquia	10
Total		**170**

4.3. Integración espacial en NoSQL

El proceso de integración se realizó en dos etapas: primero la generación del archivo GeoJSON y luego la carga en MongoDB Atlas.

4.3.1. Preprocesamiento y exportación a GeoJSON

Tras el cruce de datasets, se aplicaron las siguientes transformaciones sobre el GeoDataFrame resultante:

1. **Corrección de geometrías:** se aplicó `buffer(0)` para eliminar auto-intersecciones presentes en polígonos del MGN.
2. **Reproyección:** conversión de EPSG:4686 (MAGNA-SIRGAS) a **EPSG:4326 (WGS84)**, requerido por el estándar GeoJSON y los índices `2dsphere` de MongoDB.
3. **Cálculo de área:** las áreas se calcularon usando la proyección métrica EPSG:9377 para garantizar precisión en metros cuadrados; el resultado se almacena en km^2 como campo `area_km2`.
4. **Bounding box:** se generó para cada municipio un objeto `bbox` con los extremos geográficos (`min_lng`, `min_lat`, `max_lng`, `max_lat`), útil para filtros espaciales previos a la intersección exacta.
5. **Exportación:** el GeoDataFrame se guardó en `municipios_pdet.geojson` (65,2 MB), con 170 features de tipo `Polygon` o `MultiPolygon`.

```python
# Correccion de geometrias y reproyeccion
gdf_pdet = gdf_pdet[gdf_pdet.geometry.notnull()]
gdf_pdet["geometry"] = gdf_pdet.buffer(0)    # elimina auto-intersecciones
gdf_pdet = gdf_pdet.to_crs(epsg=4326)        # WGS84 para MongoDB

# Calculo de area en km2 con proyeccion metrica
metric = gdf_pdet.to_crs(epsg=9377)
gdf_pdet["area_km2"] = metric.area / 1_000_000

# Bounding box por municipio
bounds = gdf_pdet.geometry.bounds
gdf_pdet["bbox"] = bounds.apply(
    lambda r: {"min_lng": r.minx, "min_lat": r.miny,
               "max_lng": r.maxx, "max_lat": r.maxy}, axis=1
)
gdf_pdet.to_file("municipios_pdet.geojson", driver="GeoJSON")
```

Listing 4.1: Fragmento de load_pdet.py — procesamiento geoespacial

4.3.2. Carga en MongoDB Atlas

Los documentos se insertaron en la colección `municipios_pdet` de la base de datos **`upme_solar_db`** (MongoDB Atlas, capa gratuita, clúster `Cluster0`). Cada documento incluye los siguientes nueve campos:

Cuadro 4.2: Esquema de documento — Colección `municipios_pdet`

Campo	Tipo	Descripción
`cod_dane`	String	Código DIVIPOLA de 5 dígitos
`nombre`	String	Nombre oficial del municipio
`departamento`	String	Departamento al que pertenece
`subregion_pdet`	String	Subregión PDET según Decreto 893/2017
`area_km2`	Double	Área calculada en km² (EPSG:9377)
`pdet`	Boolean	Siempre `true` en esta colección
`geometry`	GeoJSON	Geometría completa (Polygon/MultiPolygon)
`fuente`	String	`"MGN2025"`
`cargado_en`	Date	Marca de tiempo UTC de inserción

```python
col.drop()  # limpiar inserciones previas

documentos = []
for _, fila in gdf.iterrows():
    doc = {
        "cod_dane":        str(fila["cod_dane"]),
        "nombre":          fila["Municipio"],
        "departamento":    fila["Departamento"],
        "subregion_pdet": fila["SubPDET"],
        "area_km2":        float(fila["area_km2"]),
        "pdet":            True,
        "geometry":        fila["geometry"].__geo_interface__,
        "fuente":          "MGN2025",
        "cargado_en":      datetime.utcnow()
    }
    documentos.append(doc)

col.insert_many(documentos)
# Municipios cargados: 170
```

Listing 4.2: Carga de documentos en MongoDB Atlas

Posteriormente se crearon dos índices sobre la colección:

```python
col.create_index([("geometry", "2dsphere")])        # consultas
    geoespaciales
```

```
col.create_index([("cod_dane", 1)], unique=True)    # unicidad
    por codigo DANE
```

Listing 4.3: Creación de índices en MongoDB

El índice `2dsphere` habilita los operadores `$geoIntersects` y `$geoWithin` sobre geometrías GeoJSON, mientras que el índice sobre `cod_dane` garantiza la integridad referencial y acelera las búsquedas por código municipal.

4.4. Validación de la carga

La validación se realizó en tres niveles: integridad tabular, topología espacial e integridad en MongoDB.

Integridad tabular

Cuadro 4.3: Resultados de la verificación de integridad del dataset PDET

Verificación	Resultado	Estado
Total de municipios cargados	170 / 170	✓
Geometrías inválidas	0	✓
Valores nulos en campos clave	0	✓
Códigos DANE duplicados	0	✓
Solapamientos entre municipios	0	✓
Documentos insertados en MongoDB	170	✓
Campos requeridos presentes	9 / 9	✓

Prueba del índice espacial

Se ejecutó una consulta de intersección puntual con el operador `$geoIntersects` sobre las coordenadas ($-72{,}7317°$ E, $8{,}6572°$ N), correspondientes al municipio de **Tibú (Norte de Santander)**. La respuesta del índice fue inmediata e identificó correctamente el documento asociado a dicho municipio (subregión Catatumbo), confirmando el correcto funcionamiento del índice `2dsphere`.

Visualización cartográfica

La Figura 4.1 presenta el mapa coroplético con los 170 municipios PDET coloreados por departamento, generado directamente desde el GeoDataFrame validado.

[Figura pendiente: municipios_pdet_mapa.png]

Figura 4.1: Municipios PDET en Colombia — Fuente: DANE MGN2025, elaboración propia.

4.5. Avance y resultados de la Semana 2

Durante esta entrega se completaron exitosamente las siguientes tareas:

1. **Adquisición del MGN2025:** descarga y lectura del Shapefile oficial del DANE con 1 122 municipios de Colombia.
2. **Integración de la lista PDET:** cruce por código DANE con el archivo oficial del ART, obteniendo exactamente 170 municipios en 16 subregiones.
3. **Preprocesamiento geoespacial:** corrección de geometrías, reproyección a WGS84, cálculo de áreas en km² y generación de bounding boxes.
4. **Exportación a GeoJSON:** archivo `municipios_pdet.geojson` de 65,2 MB listo para su uso en fases posteriores.
5. **Carga en MongoDB Atlas:** 170 documentos insertados en la colección `municipios_pdet` de `upme_solar_db`, con índices `2dsphere` y `cod_dane` (único) operativos.
6. **Validación integral:** cero errores en geometrías, nulos, duplicados y solapamientos; prueba del índice espacial exitosa.
7. **Visualización cartográfica:** mapa coroplético por departamento generado con Matplotlib y GeoPandas.

El principal obstáculo encontrado fue la ausencia del archivo `.shx` al ejecutar el notebook `01_integracion_pdet.ipynb` en un entorno diferente al de desarrollo original, lo que impidió que GeoPandas abriera el Shapefile. Este problema se resolvió

ejecutando el procesamiento directamente sobre el GeoJSON ya generado, garantizando la portabilidad del flujo de trabajo.

Capítulo 5

Carga e Integración de Datos de Edificaciones

Semana 3 — Entrega 3

Objetivo: Adquirir, cargar y realizar un análisis exploratorio de los conjuntos de datos de edificaciones seleccionados.
Fecha de entrega: Semana 3, antes de las 14:00 h.

5.1. Datasets seleccionados

Para este proyecto se seleccionaron los siguientes dos conjuntos de datos:

1. **Microsoft Building Footprints** (**microsoft2023buildings**)
2. **Google Open Buildings v3** (**sirko2021continental**)

[Justificar brevemente la selección y descartar el tercero si aplica.]

5.2. Dataset 1: Microsoft Building Footprints

5.2.1. Adquisición

[Describir el proceso de descarga: Planetary Computer, archivos GeoParquet por país, volumen total para Colombia.]

5.2.2. Formato y estructura

[Describir las columnas del dataset: geometry, confidence, etc. Incluir tabla de metadatos.]

5.2.3. Carga en NoSQL

[Estrategia de particionamiento, tiempos de carga, índices creados.]

5.2.4. Análisis exploratorio (EDA)

[Estadísticas básicas: total de edificaciones en Colombia, distribución de áreas, histogramas, comparación urbano/rural.]

5.3. Dataset 2: Google Open Buildings

5.3.1. Adquisición

[Tiles descargados, formato CSV/GeoJSON, identificación de tiles que intersectan con bounding box de Colombia.]

5.3.2. Carga en NoSQL e índices espaciales

[Mismo esquema que Dataset 1.]

5.3.3. Análisis exploratorio (EDA)

[Comparar cobertura y características con Microsoft.]

5.4. Comparación preliminar de datasets

Cuadro 5.1: Comparación de datasets de edificaciones para Colombia

Aspecto	**Microsoft**	**Google**
Total edificaciones (Colombia)		
Tamaño en disco		
Año de imágenes	2014–2021	*[x]*
Atributos de área		
Licencia	ODbL	CC BY-4.0 / ODbL
Tiempo de carga		

5.5. Avance y resultados de la Semana 3

[Síntesis: número total de documentos cargados por dataset, desafíos de ETL, tiempos, métricas de calidad de datos.]

Capítulo 6

Flujo de Trabajo Geoespacial Reproducible

Semana 4 — Entrega 4

Objetivo: Implementar y documentar el flujo de intersección espacial para estimar conteo y área de techumbres por municipio PDET.
Fecha de entrega: Semana 4, antes de las 14:00 h (defensa en clase).

6.1. Metodología de análisis espacial

[Describir el pipeline: consulta de intersección por municipio → filtrado por bounding box → intersección poligonal exacta → agregación. Diagramar el flujo con un esquema.]

6.1.1. Intersección espacial en NoSQL

[Mostrar las queries de intersección, operadores utilizados (`$geoIntersects`, aggregation pipeline), ejemplo de salida.]

```
pipeline = [
    {
        "$match": {
            "geometry": {
                "$geoIntersects": {
                    "$geometry": municipio_geometry
                }
            }
        }
    },
    {
        "$group": {
```

```
            "_id": None,
            "count": {"$sum": 1},
            "area_total_m2": {"$sum": "$area_m2"}
        }
    }
]
result = collection_ms.aggregate(pipeline)
```

Listing 6.1: Consulta de intersección — Edificaciones Microsoft por municipio

6.1.2. Reproducibilidad

[Describir el entorno Conda/Docker, el archivo de requerimientos y las instrucciones de ejecución del pipeline.]

6.2. Resultados por municipio PDET

6.2.1. Dataset Microsoft

Cuadro 6.1: Top 10 municipios PDET por área total de techumbres — Microsoft

Municipio	Departamento	N° edif.	Área total (m²)
[Municipio 1]			
[Municipio 2]			
[...]			

6.2.2. Dataset Google

[Tabla equivalente para Google Open Buildings.]

6.3. Visualizaciones

[Mapa coroplético — área total Microsoft]

(a) Microsoft Building Footprints

[Mapa coroplético — área total Google]

(b) Google Open Buildings

Figura 6.1: Área total de techumbres por municipio PDET según cada dataset.

6.4. Comparación entre datasets

[Análisis de concordancia: correlación de conteos, diferencias sistemáticas por región, posibles explicaciones metodológicas.]

6.5. Avance y resultados de la Semana 4

[Síntesis del pipeline, validación de resultados, hallazgos preliminares más relevantes.]

Capítulo 7

Resultados Finales y Recomendaciones para UPME

Semana 5 — Entrega 5 – Informe Final

Objetivo: Consolidar resultados, elaborar recomendaciones y entregar el informe técnico completo.
Fecha de entrega: Semana 5, antes de las 14:00 h (defensa privada).

7.1. Síntesis de resultados

[Presentar las cifras finales consolidadas: total de edificaciones y área de techumbres en los 170 municipios PDET según cada dataset. Incluir tabla resumen y gráfico comparativo.]

7.2. Análisis de potencial solar

[Estimar potencial de generación: área de techo × factor de utilización (ej. 70 %) × irradiancia promedio × eficiencia de panel. Puede basarse en datos del Atlas de Radiación Solar de Colombia.]

$$E_{\text{anual}} = A_{\text{techo}} \times \eta_{\text{util}} \times \overline{GHI} \times \eta_{\text{panel}} \times 365 \tag{7.1}$$

donde A_{techo} es el área disponible [m^2], η_{util} el factor de utilización, $\overline{GHI}$ la irradiancia diaria media [kWh/m^2/día] y η_{panel} la eficiencia del panel fotovoltaico.

7.3. Municipios prioritarios para proyectos piloto

[Proponer un ranking de municipios PDET considerando: (1) área de techo disponible, (2) irradiancia, (3) déficit de cobertura eléctrica, (4) accesibilidad. Incluir mapa de priorización.]

[Mapa final de priorización de municipios PDET para proyectos piloto]

Figura 7.1: Municipios PDET priorizados para proyectos piloto de energía solar.

7.4. Recomendaciones para UPME

R1. Validación en campo: *[Recomendación 1]*

R2. Dataset preferido: *[Recomendación 2]*

R3. Infraestructura de datos: *[Recomendación 3]*

R4. Próximos pasos: *[Recomendación 4]*

R5. *[Agregar las que sean pertinentes]*

7.5. Limitaciones y trabajo futuro

[Discutir limitaciones del análisis: calidad de datos satelitales en zonas de nubosidad alta, inclinación de techos no modelada, cambios de uso del suelo post-imagen. Proponer líneas de trabajo futuro.]

Capítulo 8

Conclusiones

[Sintetizar los principales aprendizajes técnicos y los hallazgos del análisis. Reflexionar sobre el uso de NoSQL para datos geoespaciales a gran escala y la viabilidad del enfoque para apoyar la política energética colombiana.]

Apéndice A

Repositorio y Estructura de Archivos

[Incluir URL del repositorio GitHub y árbol de directorios del proyecto.]

```
proyecto-upme-solar/
|-- README.md
|-- requirements.txt
|-- data/
|   |-- raw/
|   |   |-- mgn2025/
|   |   |-- ms_buildings/
|   |   +-- google_buildings/
|   +-- processed/
|-- notebooks/
|   |-- 01_schema_design.ipynb
|   |-- 02_pdet_integration.ipynb
|   |-- 03_buildings_loading.ipynb
|   |-- 04_spatial_analysis.ipynb
|   +-- 05_results_viz.ipynb
|-- src/
|   |-- db/
|   |-- etl/
|   +-- analysis/
|-- outputs/
|   |-- maps/
|   +-- tables/
+-- informe/
    |-- informe_upme_solar.tex
    +-- referencias.bib
```

Listing A.1: Estructura del repositorio

Apéndice B

Diccionario de Datos

[Describir todos los campos de cada colección NoSQL: nombre, tipo, descripción, ejemplo de valor.]

Apéndice C

Instrucciones de Reproducción

[Paso a paso para reproducir el análisis desde cero: instalación de dependencias, configuración de MongoDB, ejecución de notebooks en orden.]