

UNIDAD DE PLANEACIÓN MINERO ENERGÉTICA — UPME

Proyecto Final — Administración de Bases de Datos

Estimación del Potencial Solar en Municipios PDET de Colombia

Informe Técnico Final

Semana 5

Motor NoSQL: MongoDB 8.x • Datasets: Google Open Buildings V3 + Microsoft
Building Footprints
170 municipios PDET analizados

2026

0 Índice

1. Introducción	2
1.1. Objetivos	2
2. Metodología	2
2.1. Arquitectura NoSQL	2
2.2. Fuentes de Datos	3
2.3. Pipeline de Procesamiento	3
2.4. Query Central del Análisis	4
3. Resultados	4
3.1. Cobertura General	4
3.2. Top 10 Municipios con Mayor Potencial Solar	5
3.3. Análisis por Subregión PDET	6
3.4. Concordancia entre Datasets	6
4. Comparación de Datasets	6
4.1. Fortalezas y Limitaciones	7
4.2. Hallazgo sobre Cobertura de Microsoft	7
5. Recomendaciones para UPME	7
5.1. Municipios Prioritarios para Proyectos Piloto	7
5.1.1. Prioridad Alta (Top 3)	7
5.1.2. Prioridad Media (Posiciones 4–7)	8
5.2. Recomendación por Subregión	8
5.3. Recomendaciones sobre Datos	8
6. Conclusiones	9
Referencias	9

1 Introducción

El presente informe documenta los resultados del proyecto de estimación del potencial solar en los 170 municipios PDET (Programas de Desarrollo con Enfoque Territorial) de Colombia, desarrollado como proyecto final del curso de Administración de Bases de Datos. El trabajo fue realizado en apoyo a la Unidad de Planeación Minero Energética (UPME), que busca identificar territorios prioritarios para la implementación de proyectos piloto de energía solar fotovoltaica.

El enfoque metodológico adoptado se basa en el uso de soluciones NoSQL, específicamente MongoDB, para el almacenamiento, gestión y análisis de grandes volúmenes de datos geospaciales. Se evaluaron dos fuentes de datos abiertos de footprints de edificios: Google Open Buildings V3 y Microsoft Building Footprints. La estimación del potencial solar se realizó a partir del conteo de edificaciones y la sumatoria del área de techumbre disponible por municipio, dado que una mayor área de techo implica mayor superficie para la instalación de paneles solares.

1.1 Objetivos

- Diseñar e implementar una base de datos NoSQL (MongoDB) para el almacenamiento y consulta eficiente de datos geospaciales de edificios en municipios PDET.
- Integrar y comparar los datasets de Google Open Buildings V3 y Microsoft Building Footprints para los territorios PDET.
- Estimar el número de edificaciones y el área total de techumbre por municipio PDET.
- Identificar y recomendar los municipios con mayor potencial para proyectos piloto de energía solar.

2 Metodología

2.1 Arquitectura NoSQL

Se implementó la base de datos `upme_solar_db` en MongoDB 8.x (local) con tres colecciones principales:

- **municipios__pdet**: 170 documentos con los límites geográficos de los municipios PDET, obtenidos del Marco Geoestadístico Nacional (MGN 2025) del DANE.
- **goo_buildings**: 2.263.446 edificaciones del dataset Google Open Buildings V3, almacenadas como puntos centroide con área precalculada.
- **ms_buildings**: Edificaciones del dataset Microsoft Building Footprints, procesadas a nivel de centroide con área calculada en proyección EPSG:9377.

Cada colección cuenta con índice espacial `2dsphere` sobre el campo `geometry`, habilitando las operaciones `$geoIntersects` y `$geoWithin` para el cruce territorial.

2.2 Fuentes de Datos

Cuadro 1: Comparación de datasets utilizados

Aspecto	Google Buildings V3	Open Buildings	Microsoft Building Footprints
Fuente	Google Research		Bing Maps / Microsoft
Edificaciones globales	1.800 millones		999 millones
Cobertura Colombia	Explícita (Latinoamérica)		Parcial (principalmente Amazonía)
Formato original	CSV con geometría WKT		GeoJSON por línea (CSV.GZ)
Atributo de área	<code>area_in_meters</code> (precalculado)		Calculado con GeoPandas (EPSG:9377)
Campo adicional	<code>confidence</code> (0–1)		<code>height</code> (altura estimada)
Licencia	CC BY-4.0 / ODbL		ODbL
Fecha imágenes	2023		2014–2021

2.3 Pipeline de Procesamiento

El desarrollo del proyecto se realizó mediante una metodología iterativa que permitió integrar adquisición, transformación, almacenamiento y análisis de información geoespacial orientada a la estimación del potencial solar en municipios PDET.

El flujo de trabajo implementado comprendió las siguientes etapas:

1. **Definición del problema y alcance:** Se estableció como objetivo principal estimar el potencial solar a partir del área disponible de techumbres en edificaciones localizadas dentro de municipios PDET, como insumo para la priorización territorial de proyectos piloto de generación solar fotovoltaica.
2. **Adquisición de datos:** Se realizó la descarga y consolidación de los límites municipales del Marco Geoestadístico Nacional (DANE), el listado oficial de municipios PDET, el dataset Google Open Buildings V3 y los tiles de Microsoft Building Footprints.
3. **Procesamiento geoespacial:** Se desarrolló el procesamiento inicial de limpieza, validación topológica y transformación geométrica. Esto incluyó reproyección a EPSG:4326, transformación de polígonos a centroides, cálculo de áreas y asociación territorial por código DANE municipal.
4. **Reducción y optimización:** Para optimizar almacenamiento y desempeño en MongoDB, las geometrías de edificaciones fueron almacenadas como centroides con área asociada, reduciendo significativamente el tamaño de los documentos.
5. **Carga en MongoDB:** Se realizó la inserción masiva mediante lotes utilizando `insert_many(ordered=False)`, priorizando eficiencia de escritura y control de errores durante la carga.

6. **Indexación:** Se configuraron índices espaciales `2dsphere` sobre geometría y auxiliares por código municipal y variables analíticas para optimizar el rendimiento de consultas.
7. **Análisis y agregación:** Finalmente se ejecutaron consultas de agregación con MongoDB para calcular número de edificaciones, área total disponible de techumbres, área promedio por municipio y análisis comparativos entre datasets.

Este flujo permitió desarrollar una solución reproducible para análisis territorial geoespacial a escala municipal, integrando almacenamiento documental NoSQL y procesamiento espacial dentro de una misma arquitectura técnica.

2.4 Query Central del Análisis

La consulta de agregación principal utilizada para obtener los resultados por municipio fue:

```
db.goo_buildings.aggregate([
  { $match: { cod_dane_municipio: { $ne: null } } },
  { $group: {
    _id: "$cod_dane_municipio",
    n_edificios: { $sum: 1 },
    area_total_m2: { $sum: "$area_m2" },
    area_prom_m2: { $avg: "$area_m2" }
  }},
  { $sort: { area_total_m2: -1 } }
])
```

3 Resultados

3.1 Cobertura General

Cuadro 2: Resumen de cobertura por dataset

Dataset	Edificaciones totales	Municipios cubiertos	Cobertura
Google Open Buildings V3	2.263.446	164 de 170	96.5 %
Microsoft Building Footprints	—	170 de 170	100.0 %
Municipios con datos en ambos datasets: 142 (83.5 %)			




Figura 1: Comparación espacial del área total de techumbres estimada por municipio PDET utilizando Google Open Buildings V3 y Microsoft Building Footprints.

3.2 Top 10 Municipios con Mayor Potencial Solar

Cuadro 3: Top 10 municipios PDET por área total de techumbres (Google Open Buildings V3)

#	Municipio	Depto.	Subregión	Edif.	GOB km ²	MS km ²
1	Santa Marta	Magdalena	Sierra Nevada–Perijá	154601	15.0423	12.7443
2	Valledupar	Cesar	Sierra Nevada–Perijá	141586	14.4406	1.5279
3	Buenaventura	Valle del Cauca	Pacífico Medio	88341	7.1044	7.1485
4	Florencia	Caquetá	Cuenca del Caguán y Piedemonte Caqueteño	48674	6.9259	6.6879
5	Ciénaga	Magdalena	Sierra Nevada–Perijá	34439	3.6603	0.0004
6	Santander de Quilichao	Cauca	Alto Patía y Norte del Cauca	30564	3.5888	4.2361
7	San Andrés de Tumaco	Nariño	Pacífico y Frontera Nariñense	42556	3.4580	4.5247
8	Tame	Arauca	Arauca	30013	3.0001	2.7611
9	San José del Guaviare	Guaviare	Macarena–Guaviare	27652	2.9810	3.0976
10	Tierralta	Córdoba	Sur de Córdoba	37326	2.9103	2.9749

3.3 Análisis por Subregión PDET

Cuadro 4: Potencial solar agregado por subregión PDET

Subregión	Mpios	Edif. GOB	Área GOB (km ²)	Edif. MS	Área MS (km ²)
Sierra Nevada – Perijá	15	538662	50.216	151908	22.377
Alto Patía y Norte del Cauca	24	329908	28.893	271668	30.358
Cuenca del Caguán y Piedemonte Caqueteño	17	151404	19.659	133941	22.573
Montes de María	15	182105	13.188	129388	11.821
Putumayo	9	114398	11.606	108450	13.859
Macarena – Guaviare	12	93835	9.571	88007	10.746
Arauca	4	93930	8.860	74675	10.196
Sur de Córdoba	5	97986	8.121	80634	8.332
Pacífico Medio	4	99325	8.043	49596	8.785
Catatumbo	8	88369	7.690	88606	9.133




Figura 2: Comparación del área total de techumbres estimada por subregión PDET entre Google Open Buildings V3 y Microsoft Building Footprints.

3.4 Concordancia entre Datasets

De los 170 municipios PDET, 142 (83.5%) cuentan con datos en ambos datasets, permitiendo una comparación directa. Los resultados muestran que Google Open Buildings V3 detecta consistentemente un mayor número de edificaciones que Microsoft en la mayoría de los municipios, con diferencias que van desde pocos cientos hasta miles de unidades. Sin embargo, Microsoft tiende a reportar áreas promedio por edificación mayores (226–343 m² vs 80–142 m² en Google), lo que sugiere diferencias metodológicas en los modelos de detección de cada dataset.

4 Comparación de Datasets

4.1 Fortalezas y Limitaciones

Cuadro 5: Evaluación comparativa de datasets para el contexto PDET

Criterio	Google Open Buildings V3	Microsoft Building Footprints
Cobertura PDET	96.5 % (164/170 municipios)	100 % con datos, mayor densidad en Amazonía
Volumen de datos	2.263.446 edificaciones	Menor volumen por cobertura limitada en norte
Área promedio techo	80–142 m ²	107–343 m ²
Atributo de calidad	Sí (<i>confidence</i> 0–1)	No disponible
Año de imágenes	2023 (más reciente)	2014–2021
Facilidad de acceso	Alta (descarga directa)	Alta (tiles por país)
Formato	CSV + WKT (conversión requerida)	GeoJSON por línea (directo)
Recomendación	Dataset primario para PDET	Complementario para validación

4.2 Hallazgo sobre Cobertura de Microsoft

Un hallazgo significativo del proyecto fue la limitación geográfica del dataset de Microsoft para Colombia. De los 232 tiles disponibles para el país, únicamente los tiles con prefijo 032... cubren el norte de Colombia (región Caribe, Pacífico y Andes), mientras que los tiles 210... cubren la Amazonía. Esta distribución irregular explica las diferencias de cobertura observadas y es relevante para futuros proyectos que utilicen este dataset en territorios PDET del norte del país.

5 Recomendaciones para UPME

5.1 Municipios Prioritarios para Proyectos Piloto

Basándose en el criterio de mayor área total de techumbres disponible para instalación de paneles solares, se recomienda priorizar los siguientes municipios:

5.1.1 Prioridad Alta (Top 3)

1. **Santa Marta (Magdalena)** — Con 154.601 edificaciones y 15.04 km² de área de techo según Google, y 12.74 km² según Microsoft (alta concordancia entre datasets), Santa Marta ofrece el mayor potencial absoluto de la zona PDET. Su infraestructura urbana consolidada y conectividad facilitan la implementación de proyectos piloto.
2. **Valledupar (Cesar)** — Con 141.586 edificaciones y 14.44 km² de área según Google, Valledupar es el segundo municipio con mayor potencial. La diferencia

significativa con Microsoft (1.53 km²) se explica por la cobertura limitada de ese dataset en la región Caribe, por lo que se recomienda usar Google como fuente principal para este municipio.

3. **Buenaventura (Valle del Cauca)** — Con 88.341 edificaciones y 7.10 km² de área, presenta alta concordancia entre datasets (Google: 7.10 km², Microsoft: 7.15 km²), lo que refuerza la confiabilidad de las estimaciones. Su condición de municipio PDET en el Pacífico lo convierte en un candidato estratégico para proyectos de equidad territorial.

5.1.2 Prioridad Media (Posiciones 4–7)

- **Florencia (Caquetá)**: Capital departamental con buena infraestructura y 6.93 km² de área.
- **Santander de Quilichao (Cauca)**: Alta concordancia entre datasets; estratégico para la subregión Alto Patía.
- **San Andrés de Tumaco (Nariño)**: Municipio costero con alta concentración de edificaciones en zona PDET crítica.

5.2 Recomendación por Subregión

Para proyectos de impacto regional se recomienda priorizar las subregiones:

1. **Sierra Nevada – Perijá**: Mayor potencial absoluto (50.22 km² según Google). Incluye Santa Marta, Valledupar y Ciénaga.
2. **Alto Patía y Norte del Cauca**: 28.89 km² Google y 30.36 km² Microsoft (alta concordancia). 24 municipios con cobertura completa.
3. **Cuenca del Caguán y Piedemonte Caqueteño**: 19.66 km² con buena concordancia entre fuentes.

5.3 Recomendaciones sobre Datos

- **Usar Google Open Buildings V3 como fuente primaria** para los municipios PDET, dado su mayor cobertura (96.5% vs cobertura limitada de Microsoft en el norte de Colombia) y su mayor actualidad (imágenes 2023).
- **Aplicar filtro de confianza $\text{confidence} \geq 0.7$** en Google para reducir falsos positivos sin pérdida significativa de cobertura.
- **Usar Microsoft como validación cruzada** en los 142 municipios con datos en ambos datasets. Las diferencias sistemáticas en área promedio sugieren complementariedad metodológica.
- **Actualizar el análisis** con versiones futuras de Google Open Buildings, dado el ritmo de actualización del dataset.

- Para los municipios de **Bajo Cauca y Nordeste Antioqueño y Urabá Antioqueño** (sin datos en ningún dataset), se recomienda adquisición de imágenes satelitales específicas.

6 Conclusiones

Este proyecto demostró la viabilidad de usar bases de datos NoSQL (MongoDB) con índices geospaciales para el análisis masivo de datos de edificaciones en territorios PDET de Colombia. Los principales hallazgos son:

- **Factibilidad técnica:** La combinación MongoDB + índices 2dsphere permite ejecutar consultas espaciales sobre millones de documentos en segundos, haciendo el enfoque escalable para análisis nacionales.
- **Potencial solar identificado:** El análisis revela un área total de techumbres de aproximadamente **204 km²** en los 164 municipios PDET con cobertura de Google, representando un potencial significativo para la generación solar distribuida.
- **Disparidad territorial:** La concentración del potencial en pocas subregiones (Sierra Nevada–Perijá y Alto Patía acumulan casi el 40 % del área total) sugiere que una estrategia focalizada en 10–15 municipios podría maximizar el impacto inicial.
- **Limitación de Microsoft:** El dataset de Microsoft tiene cobertura geográfica incompleta para los municipios PDET del norte de Colombia, lo que limita su uso como fuente principal pero no como herramienta de validación.
- **Reproducibilidad:** El pipeline completo, desde la descarga de datos hasta la generación de resultados, es reproducible desde el repositorio GitHub del proyecto utilizando MongoDB local con el archivo `config.py` centralizado.

6 Referencias

- [1] DANE. (2025). *Marco Geoestadístico Nacional MGN2025*. Geoportal DANE. <https://geoportal.dane.gov.co>
- [2] Google Research. (2023). *Google Open Buildings V3*. <https://sites.research.google/gr/open-buildings/>
- [3] Microsoft. (2026). *Global ML Building Footprints*. <https://github.com/microsoft/GlobalMLBuildingFootprints>
- [4] ART — Agencia de Renovación del Territorio. (2024). *Municipios PDET*. <https://www.art.gov.co/subregiones-pdet>
- [5] MongoDB Inc. (2024). *Geospatial Queries — 2dsphere Index*. <https://www.mongodb.com/docs/manual/geospatial-queries/>